


Lezione 2

alberi sintattici



radice

nodo interno

foglia

padre

figli ordinati

discendente


frontiera


alberi sintattici


data $G=(V,T,P,S)$

un albero sintattico di G soddisfa:

- 1) ciascun nodo interno è etichettato da una variabile
- 2) ciascuna foglia è etichettata da variabile, o terminale o ε , in quest'ultimo caso deve essere l'unico figlio
- 3) se un nodo interno è etichettato A e i suoi figli (da sinistra a destra $X_1...X_n$, allora $A \rightarrow X_1...X_n$ è in P .







$a*(a+b00) =$
prodotto
dell'albero

abbiamo visto molti modi di caratterizzare il funzionamento delle grammatiche.

Sono:

--inferenza ricorsiva che stabilisce che w è nel linguaggio della variabile A

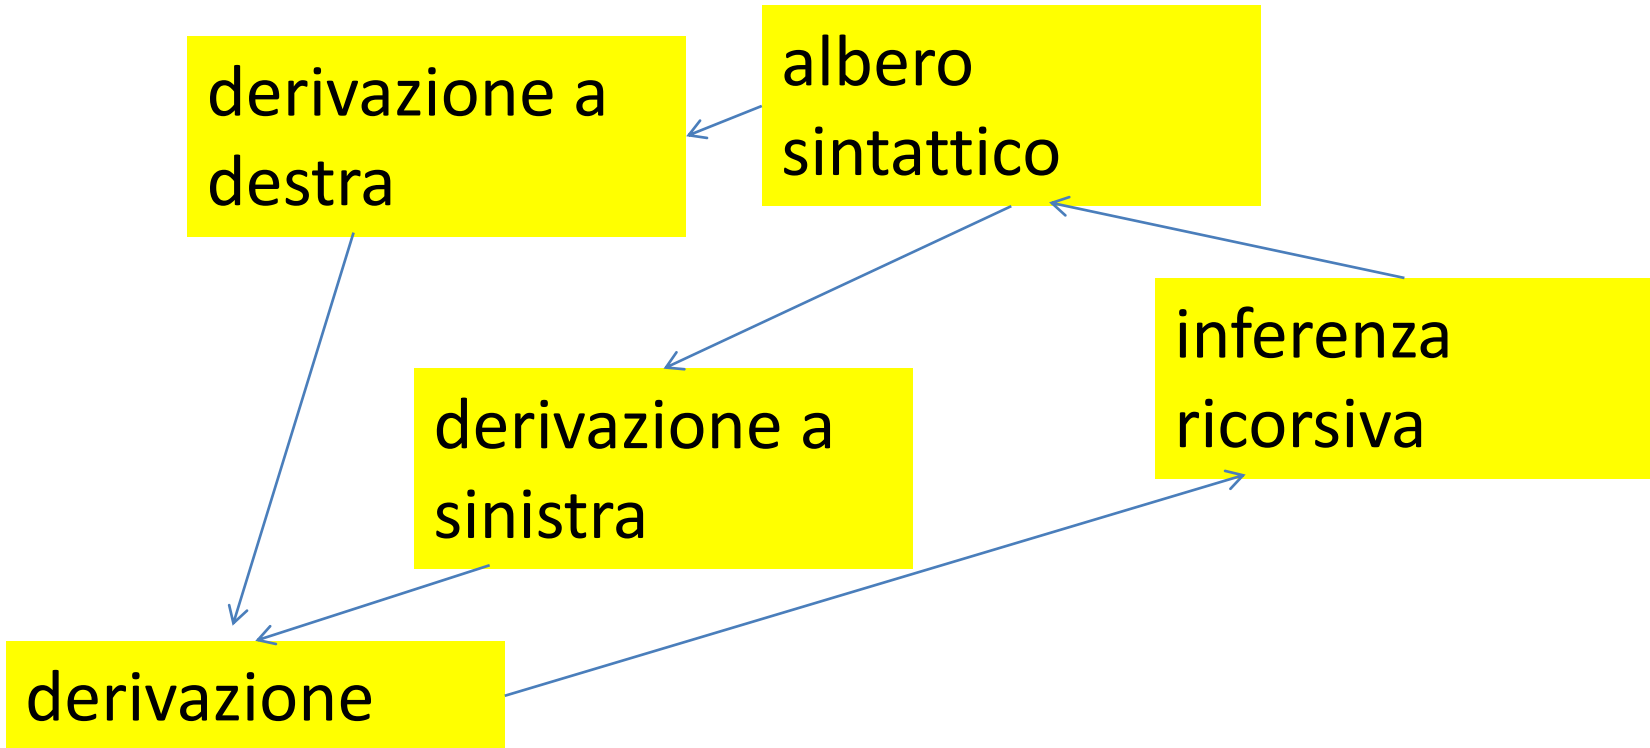
-- $A \Rightarrow^* w$

-- $A \Rightarrow^* \text{lm } w$

-- $A \Rightarrow^* \text{rm } w$

--esiste albero sintattico con radice A e prodotto w

sono tutte equivalenti



Teorema 5.12 Sia $G=(V,T,P,S)$ una CFG. Se la procedura di inferenza ricorsiva indica che la stringa terminale w è nel linguaggio della variabile A , allora esiste un albero sintattico con radice A e prodotto w .

Dimostrazione per induzione sul numero di passi dell'inferenza ricorsiva.

Base: 1 passo

deve esistere in P , $A \rightarrow w$ e quindi esiste anche l'albero sintattico desiderato.

passo induttivo: supponiamo di aver usato $n-1$ passi di inferenza, e ce l'enunciato sia valido per tutte le stringhe x e variabili B tali che l'appartenenza di x al linguaggio di B sia deducibile in $n-1$ passi di inferenza.


Consideriamo l'ultimo passo dell'inferenza di w . Questo passo usa una produzione, sia $A \rightarrow X_1X_2..X_n$, dove ogni X_i è una variabile o un terminale. possiamo scomporre $w=w_1w_2..w_n$ in modo che:

- i) se X_i è terminale allora $X_i=w_i$
- ii) se X_i è variabile allora w_i appartiene al ling. di X_i in al più $n-1$ passi

applichiamo l'ipotesi induttiva a w_i e $X_i \Rightarrow$
esiste un albero sintattico con radice X_i e
prodotto w_i .

\Rightarrow

costruiamo un albero sintattico:



con radice A e prodotto $w_1 w_2 \dots w_n = w$

dagli alberi alle derivazioni

serve osservazione:

nella grammatica delle espressioni,

$E \Rightarrow I \Rightarrow Ib \Rightarrow ab$

e quindi per ogni coppia di stringhe α e β ,

$\alpha E \beta \Rightarrow \alpha I \beta \Rightarrow \alpha Ib \beta \Rightarrow \alpha ab \beta$


$E+(E) \Rightarrow E+(I) \Rightarrow E+(Ib) \Rightarrow E+(ab)$

insomma la derivazione è libera dal contesto α, β


Teorema 5.14. Sia $G=(V,T,P,S)$ una CFG e supponiamo che esista un albero sintattico con radice A e prodotto w in T^* . Allora esiste una derivazione a sinistra $A \Rightarrow^* w$

Dimostrazione: induzione sull'altezza dell'albero.

Base: altezza 1, consiste di 1 sola produzione di G , ovvio che $A \Rightarrow w$



passo induttivo: un albero di altezza n con $n > 1$,
ha la forma, con $w = w_1 w_2 \dots w_n$



quindi P ha la produzione $A \rightarrow X_1 X_2 \dots X_n$ e,

--se X_i è terminale allora $w_i = X_i$

--se X_i è variabile è radice di un sottoalbero di
altezza $< n$ e prodotto w_i ,

per ipotesi induttiva $X_i \Rightarrow^* \text{Im } w_i$
e quindi per **la libertà di contesto**:

$$A \Rightarrow^* \text{Im } X_1 X_2 \dots X_n \Rightarrow^* \text{Im } w_1 X_2 \dots X_n \Rightarrow^* \text{Im } w_1 w_2 \dots X_n$$

rispettando l'ordine leftmost

formalmente serve un'induzione su i in $[1..n]$

d1: $E \Rightarrow \text{Im } I \Rightarrow \text{Im } a$

d2: $E \Rightarrow \text{Im } (E)$

$\Rightarrow \text{Im } (E + E) \Rightarrow \text{Im } (I + E)$

$\Rightarrow \text{Im } (a + E) \Rightarrow \text{Im } (a + I)$


$\Rightarrow \text{Im } (a + I0) \Rightarrow \text{Im } (a + I00)$

$\Rightarrow \text{Im } (a + b00)$

da cui

$A \Rightarrow \text{Im } E * E \Rightarrow \text{Im } d1 * E$

$\Rightarrow \text{Im } d1 * d2$



è ovvio che esiste un analogo teorema per le derivazioni destre

Manca un passo per chiudere il cerchio:
dalle derivazioni alle inferenze ricorsive

osserviamo che : $A \Rightarrow \text{Im } X_1 X_2 \dots X_n \Rightarrow^* \text{Im } w_1 w_2 \dots w_n = w$

è facile estrarre derivazioni

$X_i \Rightarrow^* \text{Im } w_i$

osserva che se $w_i = a$ allora la derivazione è $a \Rightarrow^* \text{Im } a$

Teorema 5.18

Sia $G=(V,T,P,S)$ e supponiamo che esista una derivazione $\text{Im } A \Rightarrow^* \text{Im } w$ con w in T^* . Allora esiste una inferenza ricorsiva che determina che w è nel linguaggio di A

Dimostrazione: per induzione sulla lunghezza della derivazione $A \Rightarrow^* \text{Im } w$

Base: lunghezza 1, esiste $A \rightarrow w$ in P con w solo i terminali, allora w è nel linguaggio di A

passo induttivo: supponiamo che sista una derivazione lm di $n+1$ passi e che l'enunciato valga per ogni derivazione di n o meno passi.

La derivazione comincia con una produzione di ,

$A \Rightarrow X_1 X_2 \dots X_n \Rightarrow^* lm w$

allora possiamo scomporre $w = w_1 w_2 \dots w_n$ in modo tale che

--se X_i è terminale allora , allora $X_i \Rightarrow^* lm w_i$ $w_i = X_i$

--se X_i è variabile allora $X_i \Rightarrow^* lm w_i$ ed avrà al più n passi

per ipotesi induttiva, esiste un'inferenza induttiva che prova che w_i è nel linguaggio di X_i ,

da $A \rightarrow X_1 X_2 \dots X_n$ si dimostra che w è nel linguaggio di A

esercizi 5.1.2 e 5.2.1

Applicazioni delle CFG

--parsing

--document type definition DTD che descrive
i tag ammessi

parsing:

il problema del bilanciamento delle parentesi

$(())$, $(())(())$ sono ben bilanciate, $((($ o $(())$ non lo sono

$G_{bal} = (\{B\}, \{ (,) \}, P, B)$, con P uguale a :

$B \rightarrow BB \mid (B) \mid \varepsilon$

è facile dimostrare che non è un linguaggio regolare

anche begin-end e anche altre parentesi

nei linguaggi ci sono anche costrutti che richiedono che ci possano essere più aperte che chiuse

Cond \rightarrow if Exp Com else Com | if Exp Com

S \rightarrow | SS | iS | iSeS

ei non va, anche iee non va, mentre ie e iiiie vanno

è chiaro che questa grammatica genera solo stringhe valide, ma le genera tutte ?

modo semplice per sapere se w in $\{i,e\}^*$ è nella grammatica:

partendo dall'e più a sinistra, trovare il primo i alla sua sinistra ed eliminarli entrambi,

continuare finché possibile e

se alla fine restano solo i o la stringa vuota, allora ok

Yacc è un parser generator: da una descrizione della grammatica genera automaticamente un parser per essa, cioè un programma che data una stringa cerca di costruire un albero sintattico della grammatica che genera la stringa.

--se riesce allora stringa è ok

--se no stringa ha errori sintattici

Exp : Id

| Exp '+' Exp {azioni da fare quando la si usa}

| Exp '*' Exp {...}

| '(' Exp ')' {.....}

;

Id : 'a' {.....}

Linguaggi di Markup

HTML e XML

DTD = Document Type Definition

```
<!DOCTYPE nome-della-DTD[  
  elenco di definizioni di elementi  
>
```

```
<!ELEMENT nome-elemento(descrizione  
dell'elemento)>
```

le descrizioni sono espressioni regolari

```
<!DOCTYPE PcSpecs [  
    <!ELEMENT PCS (PC*)>  
    <!ELEMENT PC (MODEL,PRICE,PROCESSOR,RAM,DISK+)>  
    <!ELEMENT MODEL (#PCDATA)>  
    <!ELEMENT PROCESSOR (MANF,MODEL,SPEED)>  
    ....  

```

Processor -> Manf Model Speed

Pc -> Model Price Processor Ram Disks

Disks -> Disk Disks

Ambiguità nelle grammatiche e nei linguaggi

grammatiche associano una struttura ad
programmi, DTD eccetera


ma è una struttura univoca?

non sempre


esempio di ambiguità

$E \Rightarrow E + E \Rightarrow E + E * E$

$E \Rightarrow E * E = E + E * E$



$1 + (2 * 3) = 7$
ok



$(1 + 2) * 3 = 9$
sbagliato!

$1 + 2 * 3$

Definizione:

Una CFG $G=(V,T,P,S)$ è **ambigua**, se esiste una stringa w in T^* che appartiene al linguaggio di G e per cui esistono 2 (almeno) alberi di derivazione diversi con w come prodotto.

attenzione: non derivazioni diverse ! Ma
ALBERI diversi!!

Eliminare l'ambiguità di una grammatica ?

Non è sempre possibile !!

Dipende dal linguaggio che deve generare. A volte è necessario cambiare il linguaggio introducendo dei simboli che servono solo a disambiguarlo.

Nell'esempio delle espressioni notiamo che si sono 2 cause di ambiguità:

- la precedenza degli operatori
- l'associatività degli operatori

--- Si può cambiare la grammatica in modo che implementi la precedenza e anche l'associatività:


---per la precedenza basta introdurre una variabile per ogni livello di precedenza. Quelle che corrispondono a livelli di precedenza più bassi generano le altre.

$I \rightarrow a \mid b \mid Ia \mid Ib \mid I0 \mid I1$


$F \rightarrow I \mid (E)$

$T \rightarrow F \mid T * F$

$E \rightarrow T \mid E + T$



SI



NO

ecco una grammatica che soddisfa la richiesta:

MST=Matched ST **UMST**=UnMatched ST

PROG ::= | **ST** |

ST ::= **MST** | **UMST** |

MST ::= if cond then **MST** else (M?)**ST**

UMST ::= if cond then **ST**