

# Linguaggi liberi da contesto

sintassi dei linguaggi di programmazione

costruzione automatica di parser

ci sono linguaggi non regolari

Il linguaggio dei palindromi  $L_{\text{pal}} = \{w \mid w = w^R\}$

Per alfabeto  $\{0,1\}$  contiene 0110, 11011,  $\varepsilon$ , ma non contiene 011 o 1010

$L_{\text{pal}}$  non è regolare, lo dimostriamo usando il pumping lemma

## Pumping Lemma:

per ogni linguaggio regolare  $L$ , esiste una costante  $n$  (che dipende da  $L$ ) e tale che per ogni  $w$  in  $L$  t.c.  $|w| \geq n$  allora  $w = xyz$  t.c.

(i)  $y$  non è  $\varepsilon$ ,

(ii)  $|xy| \leq n$

(iii) per ogni  $k \geq 0$ ,  $xy^kz$  è in  $L$

in  $L_{\text{pal}}$  c'è  $w=0^n10^n$

$w=xyz$  e dato che  $|xy| \leq n$  e  $y$  non è  $\varepsilon$ ,  $y$  contiene alcuni 0 e quindi  $xy^0z = xz$  non può essere in  $L_{\text{pal}}$  perché contiene meno 0 a sinistra del solo 1 rispetto agli  $n$  che sono a destra

per definire il linguaggio  $L_{\text{pal}}$  possiamo usare una definizione ricorsiva

Base:  $\varepsilon$  (stringa vuota), 0 e 1 sono in  $L_{\text{pal}}$

Induzione: se  $w$  è in  $L_{\text{pal}}$ , allora  $0w0$  e  $1w1$  sono in  $L_{\text{pal}}$

una grammatica libera dal contesto (context-free) è una notazione formale per esprimere tali definizioni ricorsive

consiste di variabili, terminali e produzioni

Per  $L_{\text{pal}}$  definiamo  $G_{\text{pal}}$

- |                             |   |                           |
|-----------------------------|---|---------------------------|
| 1. $P \rightarrow \epsilon$ | } | base della<br>definizione |
| 2. $P \rightarrow 0$        |   |                           |
| 3. $P \rightarrow 1$        |   |                           |
| 4. $P \rightarrow 0 P 0$    |   | passo induttivo           |
| 5. $P \rightarrow 1 P 1$    |   |                           |

usiamo  $G_{\text{pal}}$  per generare  $L_{\text{pal}}$

# Definizione di grammatica libera da contesto

1. insieme finito  $T$  di simboli terminali che formano le stringhe del linguaggio (per  $L_{pal}$  0 e 1)
2. insieme finito  $V$  di variabili (anche nonterminali); ogni variabile genera un linguaggio (per  $L_{pal}$  c'è solo la variabile  $P$ )
3. un simbolo iniziale ( $S$ ) che genera il linguaggio da definire (in  $L_{pal}$  sarà  $P$ )
4. un insieme finito ( $P$  o  $R$ ) di produzioni o regole che hanno forma: parte sinistra  $\rightarrow$  parte destra

dove, la parte sinistra è una variabile e la destra è una stringa in  $(V \cup T)^*$ , quindi anche vuota e composta di terminali e/o variabili, la chiameremo forma sentenziale

$$G_{\text{pal}} = (\{P\}, \{0,1\}, R, P)$$

dove  $R$  contiene le 5 regole:

1.  $P \rightarrow \varepsilon$
2.  $P \rightarrow 0$
3.  $P \rightarrow 1$
4.  $P \rightarrow 0P0$
5.  $P \rightarrow 1P1$

notazione compatta:

$$P \rightarrow \varepsilon \mid 0 \mid 1 \mid 0P0 \mid 1P1$$



# Linguaggio di una grammatica

Una CFG serve per stabilire se determinate stringhe appartengono al linguaggio della grammatica

2 strade:

--dalla sinistra a destra: derivazione

--da destra a sinistra : inferenza ricorsiva

derivazione, indicata  $\Rightarrow$  è relazione tra forme sentenziali, definita come segue:

sia  $G=(V,T,R,S)$  e sia  $\alpha A \beta$  dove  $\alpha$  e  $\beta$  sono forme sentenziali ed  $A$  è in  $V$ , sia  $A \rightarrow \gamma$  in  $R$ , allora  $\alpha A \beta \Rightarrow \alpha \gamma \beta$

$\Rightarrow^*$  è la chiusura riflessiva e transitiva di  $\Rightarrow$

significa zero o più passi di  $\Rightarrow$

definizione di  $\Rightarrow^*$

base: per qualsiasi forma sentenziale  $\alpha$ ,  $\alpha \Rightarrow^* \alpha$

induzione :  $\alpha \Rightarrow^* \beta$  e  $\beta \Rightarrow \gamma$ , allora  $\alpha \Rightarrow^* \gamma$

Definizione: linguaggio di una grammatica

Dato  $G=(V,T,R,S)$ ,  $L(G) = \{ w \text{ in } T^* \mid S \Rightarrow^* w \}$

linguaggio del nonterminale  $X$ ,

$L(X) = \{ w \text{ in } T^* \mid X \Rightarrow^* w \}$

derivazioni di  $G_{\text{pal}}$ :

$P \rightarrow \varepsilon \mid 0 \mid 1 \mid 0P0 \mid 1P1$

$P \Rightarrow 0P0 \Rightarrow 00P00 \Rightarrow 001P100 \Rightarrow 0010100$

$P \Rightarrow *0010100$

## inferenza ricorsiva di 0010100

1)  $P \rightarrow \varepsilon$

2)  $P \rightarrow 0$

3)  $P \rightarrow 1$

4)  $P \rightarrow 0P0$

5)  $P \rightarrow 1P1$

etichetta	stringa	V	produzione	Str. usate
(i)	0	P	2	--
(ii)	101	P	5	(i)
(iii)	01010	P	4	(ii)
(iv)	0010100	P	4	(iii)

$L(G)$  è l'insieme delle stringhe di terminali per cui esiste un'inferenza ricorsiva

Teorema.  $L(G_{\text{pal}})$  è l'insieme delle palindrome su  $\{0,1\}$

Dimostrazione:  $w$  in  $L(G_{\text{pal}})$  se e solo se è palindromo.

(se  $\leq$ ) supponiamo che  $w$  sia palindroma.

Mostriamo per induzione su  $|w|$  che  $w$  in  $L(G_{\text{pal}})$ .

Base:  $|w|=0$  o  $1$ . Se  $w=\varepsilon$ , allora  $w$  in  $L(G_{\text{pal}})$ , se  $w=0/1$  lo stesso.

Induzione: supponiamo che  $|w|=n \geq 2$ . Poichè  $w=w^R$ , deve iniziare e finire con lo stesso simbolo, quindi  $w=0w'0$  o  $1w'1$  e  $w'$  deve essere palindromo,

ma essendo  $|w'| < n$ , per ipotesi induttiva,  $w'$  è in  $L(G_{\text{pal}})$  e quindi, viste le produzioni  $P \rightarrow 0P0 \mid 1P1$  di  $G_{\text{pal}}$  anche  $w$  lo è.

(solo se  $\Rightarrow$ ) se  $w$  in  $L(G_{\text{pal}})$  allora è palindromo.  
Induzione sulla lunghezza della derivazione.

Base: 1 sola produzione,  $w = \varepsilon$  o  $0$  o  $1$ , sono palindromi

Induzione: supponiamo che  $w$  sia generata in  $n+1$  passi, e che l'enunciato sia vero per tutte le stringhe generate in  $n$  passi. Una tale derivazione deve iniziare con  $P \Rightarrow 0P0 \mid 1P1$  e poi  $0x0 \mid 1x1 = w$



ma allora  $P \Rightarrow *x$  in  $n$  passi e quindi per ipotesi induttiva,  $x$  è palindroma per cui anche  $0x0$  e  $1x1$  lo sono.

altro esempio: vogliamo una grammatica che generi espressioni come  $a+b*a1*(b1+aa0)$   
le operazioni sono  $*$  e  $+$  e gli operandi sono identificatori che iniziano per  $a$  o  $b$  e continuano con  $\{a,b,0,1\}^*$

Servono 2 variabili,  $E$  che descrive le espressioni e  $I$  che descrive gli identificatori.  
Il linguaggio generato da  $I$  è regolare:

$(a+b)(a+b+0+1)^*$

$I \rightarrow a \mid b \mid Ia \mid Ib \mid I0 \mid I1$

Le regole per E sono:

$$E \rightarrow I \mid E + E \mid E * E \mid (E)$$

La grammatica è:

$$G = (\{E, I\}, \{a, b, 0, 1, *, +, (, )\}, R, E)$$

dove R contiene le regole per I e per E

esempio: derivazione di  $a^*(a+b00)$

$E \rightarrow I \mid E+E \mid E^*E \mid (E)$

$I \rightarrow a \mid b \mid Ia \mid Ib \mid I0 \mid I1$

$E \Rightarrow \underline{E}^*E \Rightarrow \underline{I}^*E \Rightarrow a^*E \Rightarrow a^*(E) \Rightarrow a^*(\underline{E}+E) \Rightarrow$   
 $a^*(\underline{I}+E) \Rightarrow a^*(a+\underline{E}) \Rightarrow a^*(a+\underline{I}) \Rightarrow a^*(a+\underline{I}0) \Rightarrow$   
 $a^*(a+\underline{I}00) \Rightarrow a^*(a+b00)$

sono possibili scelte diverse per ottenere la stessa stringa

## leftmost derivation e rightmost derivation

si sceglie sempre la variabile più a sinistra/destra della forma sentenziale:

$\Rightarrow_{lm}$      $\Rightarrow_{rm}$

Notazione:

--a, b    sono terminali

--A,B,.. sono variabili

--w, z,.. sono stringhe di terminali

--X, Y    sono o terminali o variabili

-- $\alpha, \beta, \dots$  sono forme sentenziali

la derivazione di  $a^*(a+b00)$  che abbiamo visto è leftmost

osserva che esiste anche una derivazione rm di  $a^*(a+b00)$

forme sentenziali: data  $G=(V,T,P,S)$

se  $S \Rightarrow^{rm*} \alpha$

allora  $\alpha$  è una forma sentenziale destra

in modo simile se  $S \Rightarrow^{lm*} \alpha$

forma  $\alpha$  è forma sentenziale sinistra

esistono forme sentenziali che non sono né  
destra né sinistra

## inferenza ricorsiva di $a^*(a+b00)$

1.  $E \rightarrow I$
2.  $E \rightarrow E + E$
3.  $E \rightarrow E * E$
4.  $E \rightarrow (E)$
5.  $I \rightarrow a$
6.  $I \rightarrow b$
7.  $I \rightarrow Ia$
8.  $I \rightarrow Ib$
9.  $I \rightarrow I0$
10.  $I \rightarrow I1$

etichetta	stringa	V	Prod	stringhe usate
(i)	a	I	5	—
(ii)	b	I	6	—
(iii)	b0	I	9	(ii)
(iv)	b00	I	9	(iii)
(v)	a	E	1	(i)
(vi)	b00	E	1	(iv)
(vii)	a + b00	E	2	(v), (vi)
(viii)	(a + b00)	E	4	(vii)
(ix)	a * (a + b00)	E	3	(v), (viii)



# ESERCIZI

1) Which language is generated by the grammar  $G$  given by the productions

$$S \rightarrow aSa \mid aBa$$

$$B \rightarrow bB \mid b$$

2) Find a CFG that generates the language:

$$L(G) = \{ a^n b^m c^m d^{2n} \mid n \geq 0, m > 0 \}.$$

3) Find a CFG that generates the language

$$L(G) = \{ a^n b^m \mid 0 \leq n \leq m \leq 2n \}.$$

4) Consider the grammar

$$S \rightarrow abScB \mid \varepsilon$$

$$B \rightarrow bB \mid b$$

What language does it generate?

## Esercizi 5.1.1 trovare grammatiche per:

- a)  $\{0^n 1^n \mid n \geq 1\}$
- b)  $\{a^i b^j c^k \mid i \neq j \text{ o } j \neq k\}$
- c) ! l'insieme di tutte le stringhe in  $\{a,b\}^*$  t.c.  
non siano ww
- d) !! l'insieme di tutte le stringhe in  $\{a,b\}^*$   
con un numero doppio di b rispetto agli a

interessanti:

esercizio 5.1.2, 5.1.3 e 5.1.4